Python, Deep Learning and Computer Vision

Tentativo di implementazione di un modello di Machine Learning predittivo delle complicanze neonatali e materne, basato sui Big Data della natalità statunitense (NBER / NVSS)

Roberto Vicini

Obiettivo e Contesto Sanitario

La Sfida Clinica: Gli eventi avversi materni e neonatali sono statisticamente rari ma estremamente critici. Identificarli precocemente permette di salvare vite e ottimizzare le risorse ospedaliere.

La Soluzione Proposta: Sfruttare i modelli predittivi e i dati storici strutturati per mappare e anticipare i fattori di rischio clinici latenti prima o durante il parto.

I Tre Target di Previsione del Modello:

- **Morbilità Materna:** monitoraggio di eventi gravi (es. rotture uterine, emorragie, ricoveri in terapia intensiva).
- **Complicazioni Neonatali:** eventi acuti post-parto (es. ventilazione assistita prolungata, ammissione immediata in TIN).
- **Anomalie Congenite:** identificazione precoce di malformazioni o alterazioni cromosomiche alla nascita (es. sindrome di Down).

Analisi e Gestione dei Dati (Big Data)

La Fonte Dati: Registro Nazionale 'National Vital Statistics System' (NVSS) distribuito dal NBER statunitense, contenente oltre 2 milioni di record per singolo anno.

Le Feature di Input (Oltre 118 Indicatori):

- **Indicatori Demografici:** Età dei genitori, livello di istruzione complessivo, stato civile, area geografica.
- **Indicatori Clinici:** Peso alla nascita, età gestazionale esatta, livello di cure prenatali ricevute, anamnesi del parto.

Pre-processing e Pipeline di Pulizia: Identificazione e rimozione dei valori mancanti codificati nei file Stata (es. codici errore 88, 99 convertiti in NaN). Normalizzazione delle feature numeriche ed Encoding per le variabili categoriche.

Pipeline di Machine Learning e Validazione

Algoritmo di Classificazione: Scelta di XGBoost (XGBClassifier) in quanto viene indicato come ottimale per efficienza computazionale con strutture dati tabulari complesse, estese e fortemente sbilanciate.

Strategia di Validazione: Implementazione di una Stratified 5-Fold Cross-Validation. Questo approccio è stato scelto per garantire che la rarità degli eventi clinici avversi sia equamente distribuita e preservata sia nel train che nel test set, evitando overfitting.

Mitigazione dello Sbilanciamento degli outcome:

- **Bilanciamento Algoritmico:** Calcolo del fattore 'scale_pos_weight' integrato direttamente in XGBoost sulla base del rapporto positivi/negativi degli outcome del train.
- **Soglia Dinamica:** Spostamento della soglia classica (0.50) calcolata analizzando la curva Precision-Recall per ottimizzare l'F1-Score specifico del target.

Output del Modello e Sviluppi Futuri

Analisi Comparativa delle Metriche: Il framework confronta le prestazioni dei modelli standard con quelli calibrati. L'obiettivo è tracciare il miglior bilanciamento tra Precision (riduzione dei falsi allarmi clinici) e Recall (capacità di intercettare i veri casi a rischio).

Scalabilità e Limiti di Calcolo Correnti: Attualmente la pipeline lavora su un campionamento statistico controllato (10% dei dati dell'anno 2023), dovuta alla indisponibilità di risorse hardware adeguate. Lo script è predisposto per una successiva espansione allo storico completo (1994-2024).